INTRODUÇÃO À PROGRAMAÇÃO PARA GPUS USANDO CUDA

Pedro Bruel phrb@ime.usp.br 29 de Setembro de 2015



Instituto de Matemática e Estatística Universidade de São Paulo

ROTEIRO

1. Introdução

- · Recapitulando: Um template para programas CUDA
- · Profilers e Debuggers

ROTEIRO

1. Introdução

- · Recapitulando: Um template para programas CUDA
- · Profilers e Debuggers

2. Ferramentas

- · nvcc
- · nvprof
- \cdot cuda-gdb
- \cdot cuda-memcheck

RECURSOS

Os *pdf*s com as aulas e todo o código fonte usado nos exemplos estão no GitHub:

 ${}^{\bullet}$ github.com/phrb/aulas-gpu

RECURSOS

Os *pdf*'s com as aulas e todo o código fonte usado nos exemplos estão no GitHub:

• github.com/phrb/aulas-gpu

Outros recursos:

- · CUDA Toolkit Documentation: docs.nvidia.com/cuda
- GPU Teaching Kit: syllabus.gputeachingkit.com
- iPython: ipython.org/notebook.html
- · CUDA Toolkit: developer.nvidia.com/cuda-toolkit
- Anaconda: continuum.io/downloads

// Código em src/cuda—samples/0_Simple/vectorAdd/vectorAdd.cu #include <cuda_runtime.h>

```
// Código em src/cuda—samples/0_Simple/vectorAdd/vectorAdd.cu
#include <cuda_runtime.h>

float *h_A = (float *)malloc(size);
if (h_A == NULL) { ... };

err = cudaMalloc((void **)&d_A, size);
err = cudaMemcpy(d_A, h_A, size, cudaMemcpyHostToDevice);
if (err != cudaSuccess) { ... };
```

```
// Código em src/cuda—samples/O Simple/vectorAdd/vectorAdd.cu
#include <cuda runtime.h>
float *h_A = (float *)malloc(size);
if (h_A == NULL) { ... };
err = cudaMalloc((void **)&d A, size);
err = cudaMemcpy(d_A, h_A, size, cudaMemcpyHostToDevice);
if (err != cudaSuccess) { ... }:
int threadsPerBlock = 256:
int blocksPerGrid =(numElements + threadsPerBlock - 1) /
    threadsPerBlock:
vectorAdd << blocksPerGrid . threadsPerBlock >> > (d A. d B. d C.
    numElements);
err = cudaGetLastError()
err = cudaDeviceSynchronize()
if (err != cudaSuccess) { ... };
```

```
// Código em src/cuda—samples/O Simple/vectorAdd/vectorAdd.cu
#include <cuda runtime.h>
float *h_A = (float *)malloc(size);
if (h_A == NULL) { ... };
err = cudaMalloc((void **)&d A, size);
err = cudaMemcpy(d_A, h_A, size, cudaMemcpyHostToDevice);
if (err != cudaSuccess) { ... };
int threadsPerBlock = 256:
int blocksPerGrid =(numElements + threadsPerBlock - 1) /
    threadsPerBlock:
vectorAdd << blocksPerGrid . threadsPerBlock >> > (d A. d B. d C.
    numElements);
err = cudaGetLastError()
err = cudaDeviceSynchronize()
if (err != cudaSuccess) { ... };
err = cudaMemcpy(h_C, d_C, size, cudaMemcpyDeviceToHost);
err = cudaFree(d A);
if (err != cudaSuccess) { ... };
```

Exemplos no repositório:

- \cdot src/cuda-samples/0_Simple
- \cdot src/cuda-samples/0_Simple/vectorAdd/vectorAdd.cu
- \cdot src/cuda-samples/0_Simple/template_runtime/template_runtime.cu

Profilers:

- · Ferramentas para análise de código em tempo de execução
- · A intenção é otimizar o código

Profilers:

- · Ferramentas para análise de código em tempo de execução
- · A intenção é otimizar o código

Como?

- · Instrumentação do Código
- · Captura de eventos
- · Geração de dados

Profilers:

- · Ferramentas para análise de código em tempo de execução
- · A intenção é otimizar o código

Como?

- · Instrumentação do Código
- · Captura de eventos
- · Geração de dados

O quê?

- · Consumo de memória
- · Frequência e duração de chamadas de função
- · Uso de instruções específicas

Profilers:

- · Ferramentas para análise de código em tempo de execução
- · A intenção é otimizar o código

Como?

- · Instrumentação do Código
- · Captura de eventos
- · Geração de dados

O quê?

- · Consumo de memória
- · Frequência e duração de chamadas de função
- Uso de instruções específicas
- · Bottlenecks, ou Gargalos, de desempenho

Debuggers:

- · Ferramentas para análise de código em tempo de execução
- · As intenções são consertar bugs e realizar testes

Debuggers:

- · Ferramentas para análise de código em tempo de execução
- · As intenções são consertar bugs e realizar testes

Como?

- · Instrumentação do Código
- Execução passo-a-passo
- Breakpoints

Debuggers:

- · Ferramentas para análise de código em tempo de execução
- · As intenções são consertar bugs e realizar testes

Como?

- · Instrumentação do Código
- · Execução passo-a-passo
- Breakpoints

O quê?

- · Acessos e vazamentos de memória
- Pode ajudar com vários tipos de bugs ©

RECURSOS

Os próximos *slides* foram adaptados do material disponível no GPU Teaching Kit:

· syllabus.gputeachingkit.com



GPU Teaching Kit





The GPU Teaching Kit is licensed by NVIDIA and the University of Illinois under the <u>Creative Commons Attribution-NonCommercial 4.0 International License.</u>



GPU Teaching Kit

Accelerated Computing



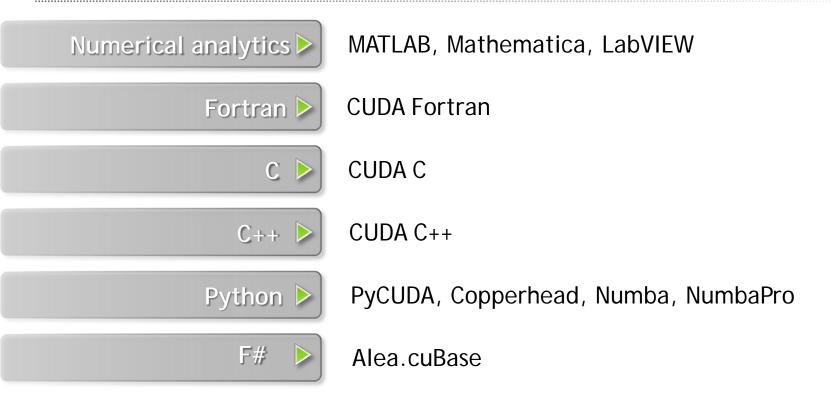
Lecture 2.4 – Introduction to CUDA C

Introduction to the CUDA Toolkit

Objective

- To become familiar with some valuable tools and resources from the CUDA Toolkit
 - Compiler flags
 - Debuggers
 - Profilers

GPU Programming Languages



CUDA - C

Applications

Libraries

Compiler <u>Direc</u>tives Programming Languages

Easy to use Most Performance Easy to use Portable code

Most Performance Most Flexibility

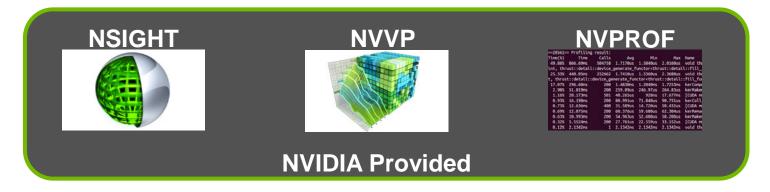
NVCC Compiler

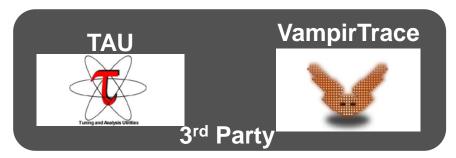
- NVIDIA provides a CUDA-C compiler
 - nvcc
- NVCC compiles device code then forwards code on to the host compiler (e.g. g++)
- Can be used to compile & link host only applications

Compiler Flags

- Remember there are two compilers being used
 - NVCC: Device code
 - Host Compiler: C/C++ code
- NVCC supports some host compiler flags
 - If flag is unsupported, use –Xcompiler to forward to host
 - e.g. –Xcompiler –fopenmp
- Debugging Flags
 - g: Include host debugging symbols
 - G: Include device debugging symbols
 - lineinfo: Include line information with symbols

Developer Tools - Profilers





https://developer.nvidia.com/performance-analysis-tools

NVPROF

Command Line Profiler

- Compute time in each kernel
- Compute memory transfer time
- Collect metrics and events
- Support complex process hierarchy's
- Collect profiles for NVIDIA Visual Profiler
- No need to recompile

NVIDIA's Visual Profiler (NVVP)

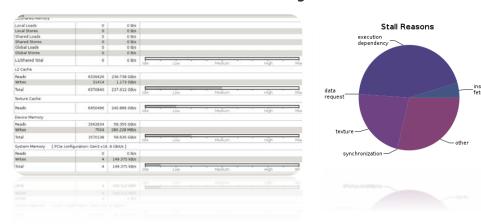
Timeline



Guided System



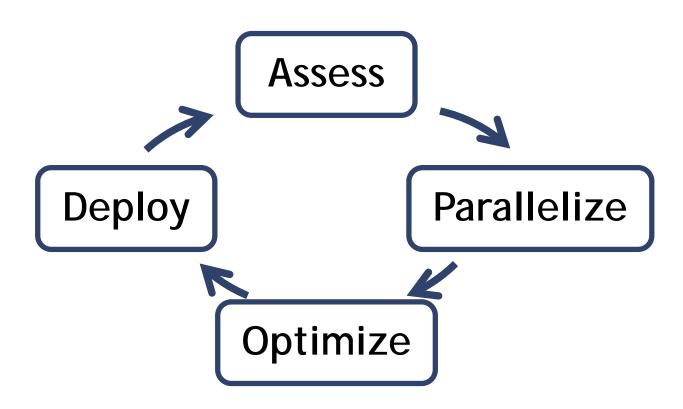
Analysis



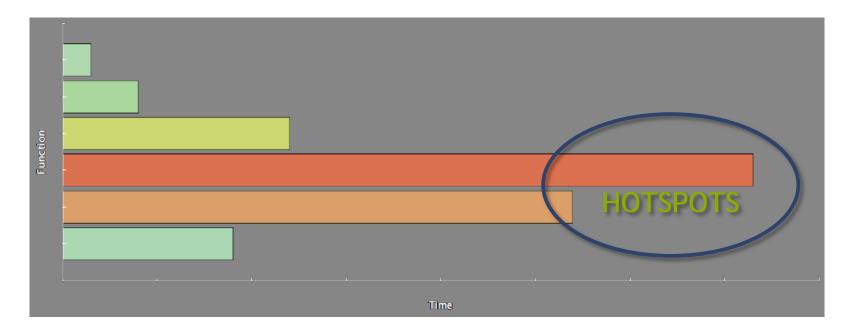
Profiler Summary

- Many profile tools are available
- NVIDIA Provided
 - NVPROF: Command Line
 - NVVP: Visual profiler
 - NSIGHT: IDE (Visual Studio and Eclipse)
- 3rd Party
 - TAU
 - VAMPIR

Optimization



Assess



- Profile the code, find the hotspot(s)
- Focus your attention where it will give the most benefit



Parallelize

Applications

Libraries

Compiler Directives

Programming Languages

Optimize

Timeline



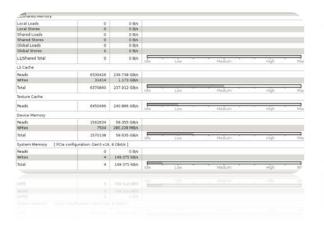
Guided System

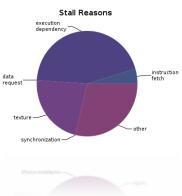


Rerun Analysis

If you modify the kernel you need to rerun your application to update this analysis.

Analysis





Developer Tools - Debuggers





https://developer.nvidia.com/debugging-solutions

CUDA-GDB

- cuda-gdb is an extension of GDB
 - Provides seamless debugging of CUDA and CPU code
- Works on Linux and Macintosh
 - For a Windows debugger use NSIGHT Visual Studio Edition

http://docs.nvidia.com/cuda/cuda-gdb

CUDA-MEMCHECK

- Memory debugging tool
 - No recompilation necessary%> cuda-memcheck ./exe
- Can detect the following errors
 - Memory leaks
 - Memory errors (OOB, misaligned access, illegal instruction, etc)
 - Race conditions
 - Illegal Barriers
 - Uninitialized Memory
- For line numbers use the following compiler flags:
 - Xcompiler -rdynamic -lineinfo

http://docs.nvidia.com/cuda/cuda-memcheck



INTRODUÇÃO À PROGRAMAÇÃO PARA GPUS USANDO CUDA

Pedro Bruel phrb@ime.usp.br 29 de Setembro de 2015



Instituto de Matemática e Estatística Universidade de São Paulo