### INTRODUÇÃO À PROGRAMAÇÃO PARA GPUS USANDO CUDA

Pedro Bruel phrb@ime.usp.br 29 de Setembro de 2015



Instituto de Matemática e Estatística Universidade de São Paulo

#### **ROTEIRO**

#### 1. Introdução

- · Recapitulando: Um template para programas CUDA
- · Profilers e Debuggers

#### **ROTEIRO**

#### 1. Introdução

- · Recapitulando: Um template para programas CUDA
- · Profilers e Debuggers

#### 2. Ferramentas

- · nvcc
- · nvprof
- $\cdot$  cuda-gdb
- $\cdot$  cuda-memcheck

#### **RECURSOS**

Os *pdf*s com as aulas e todo o código fonte usado nos exemplos estão no GitHub:

 ${}^{\bullet}$ github.com/phrb/aulas-gpu

#### RECURSOS

Os *pdf*'s com as aulas e todo o código fonte usado nos exemplos estão no GitHub:

• github.com/phrb/aulas-gpu

#### Outros recursos:

- · CUDA Toolkit Documentation: docs.nvidia.com/cuda
- GPU Teaching Kit: syllabus.gputeachingkit.com
- iPython: ipython.org/notebook.html
- · CUDA Toolkit: developer.nvidia.com/cuda-toolkit
- Anaconda: continuum.io/downloads

// Código em src/cuda—samples/0\_Simple/vectorAdd/vectorAdd.cu #include <cuda\_runtime.h>

```
// Código em src/cuda—samples/0_Simple/vectorAdd/vectorAdd.cu
#include <cuda_runtime.h>

float *h_A = (float *)malloc(size);
if (h_A == NULL) { ... };

err = cudaMalloc((void **)&d_A, size);
err = cudaMemcpy(d_A, h_A, size, cudaMemcpyHostToDevice);
if (err != cudaSuccess) { ... };
```

```
// Código em src/cuda—samples/O Simple/vectorAdd/vectorAdd.cu
#include <cuda runtime.h>
float *h_A = (float *)malloc(size);
if (h_A == NULL) { ... };
err = cudaMalloc((void **)&d A, size);
err = cudaMemcpy(d_A, h_A, size, cudaMemcpyHostToDevice);
if (err != cudaSuccess) { ... }:
int threadsPerBlock = 256:
int blocksPerGrid =(numElements + threadsPerBlock - 1) /
    threadsPerBlock:
vectorAdd << blocksPerGrid . threadsPerBlock >> > (d A. d B. d C.
    numElements);
err = cudaGetLastError()
err = cudaDeviceSynchronize()
if (err != cudaSuccess) { ... };
```

```
// Código em src/cuda—samples/O Simple/vectorAdd/vectorAdd.cu
#include <cuda runtime.h>
float *h_A = (float *)malloc(size);
if (h_A == NULL) { ... };
err = cudaMalloc((void **)&d A, size);
err = cudaMemcpy(d_A, h_A, size, cudaMemcpyHostToDevice);
if (err != cudaSuccess) { ... };
int threadsPerBlock = 256:
int blocksPerGrid =(numElements + threadsPerBlock - 1) /
    threadsPerBlock:
vectorAdd << blocksPerGrid . threadsPerBlock >> > (d A. d B. d C.
    numElements);
err = cudaGetLastError()
err = cudaDeviceSynchronize()
if (err != cudaSuccess) { ... };
err = cudaMemcpy(h_C, d_C, size, cudaMemcpyDeviceToHost);
err = cudaFree(d A);
if (err != cudaSuccess) { ... };
```

#### Exemplos no repositório:

- $\cdot$  src/cuda-samples/0\_Simple
- $\cdot$ src/cuda-samples/0\_Simple/vectorAdd/vectorAdd.cu
- $\cdot$ src/cuda-samples/0\_Simple/template\_runtime/template\_runtime.cu

#### Profilers:

- · Ferramentas para análise de código em tempo de execução
- · A intenção é otimizar o código

#### Profilers:

- · Ferramentas para análise de código em tempo de execução
- · A intenção é otimizar o código

#### Como?

- · Instrumentação do Código
- · Captura de eventos
- · Geração de dados

#### Profilers:

- · Ferramentas para análise de código em tempo de execução
- · A intenção é otimizar o código

#### Como?

- · Instrumentação do Código
- · Captura de eventos
- · Geração de dados

#### O quê?

- · Consumo de memória
- · Frequência e duração de chamadas de função
- · Uso de instruções específicas

#### Profilers:

- · Ferramentas para análise de código em tempo de execução
- · A intenção é otimizar o código

#### Como?

- · Instrumentação do Código
- · Captura de eventos
- · Geração de dados

#### O quê?

- · Consumo de memória
- · Frequência e duração de chamadas de função
- Uso de instruções específicas
- · Bottlenecks, ou Gargalos, de desempenho

#### Debuggers:

- · Ferramentas para análise de código em tempo de execução
- · As intenções são consertar bugs e realizar testes

#### Debuggers:

- · Ferramentas para análise de código em tempo de execução
- · As intenções são consertar bugs e realizar testes

#### Como?

- · Instrumentação do Código
- Execução passo-a-passo
- Breakpoints

#### Debuggers:

- · Ferramentas para análise de código em tempo de execução
- · As intenções são consertar bugs e realizar testes

#### Como?

- · Instrumentação do Código
- · Execução passo-a-passo
- Breakpoints

#### O quê?

- · Acessos e vazamentos de memória
- Pode ajudar com vários tipos de bugs ©

#### **RECURSOS**

Os próximos *slides* foram adaptados do material disponível no GPU Teaching Kit:

· syllabus.gputeachingkit.com



## **GPU Teaching Kit**





The GPU Teaching Kit is licensed by NVIDIA and the University of Illinois under the <u>Creative Commons Attribution-NonCommercial 4.0 International License.</u>



## **GPU Teaching Kit**

**Accelerated Computing** 



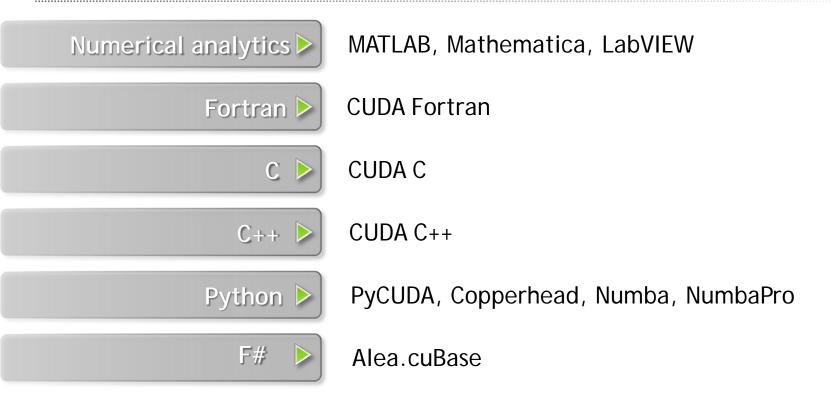
## Lecture 2.4 – Introduction to CUDA C

Introduction to the CUDA Toolkit

# Objective

- To become familiar with some valuable tools and resources from the CUDA Toolkit
  - Compiler flags
  - Debuggers
  - Profilers

# **GPU Programming Languages**



## CUDA - C

## **Applications**

Libraries

Compiler <u>Direc</u>tives Programming Languages

Easy to use Most Performance Easy to use Portable code

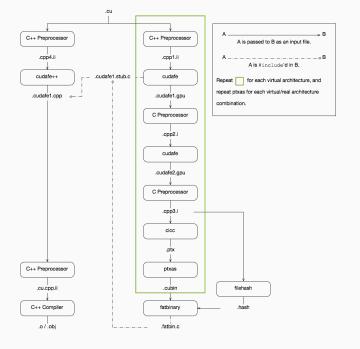
Most Performance Most Flexibility

# **NVCC Compiler**

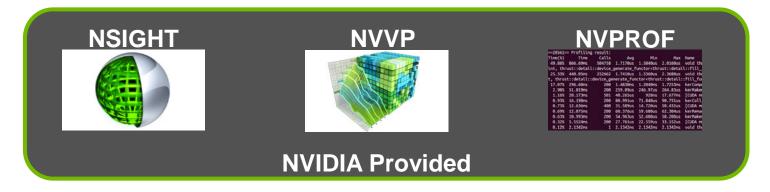
- NVIDIA provides a CUDA-C compiler
  - nvcc
- NVCC compiles device code then forwards code on to the host compiler (e.g. g++)
- Can be used to compile & link host only applications

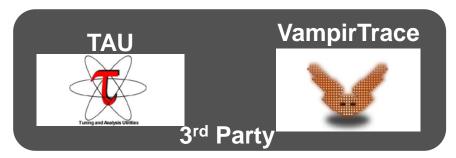
# Compiler Flags

- Remember there are two compilers being used
  - NVCC: Device code
  - Host Compiler: C/C++ code
- NVCC supports some host compiler flags
  - If flag is unsupported, use –Xcompiler to forward to host
    - e.g. –Xcompiler –fopenmp
- Debugging Flags
  - g: Include host debugging symbols
  - G: Include device debugging symbols
  - lineinfo: Include line information with symbols



# **Developer Tools - Profilers**





https://developer.nvidia.com/performance-analysis-tools

## **NVPROF**

#### Command Line Profiler

- Compute time in each kernel
- Compute memory transfer time
- Collect metrics and events
- Support complex process hierarchy's
- Collect profiles for NVIDIA Visual Profiler
- No need to recompile

# **NVIDIA's Visual Profiler (NVVP)**

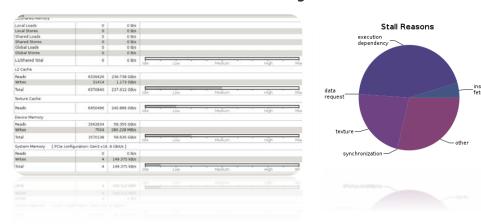
#### **Timeline**



### Guided System



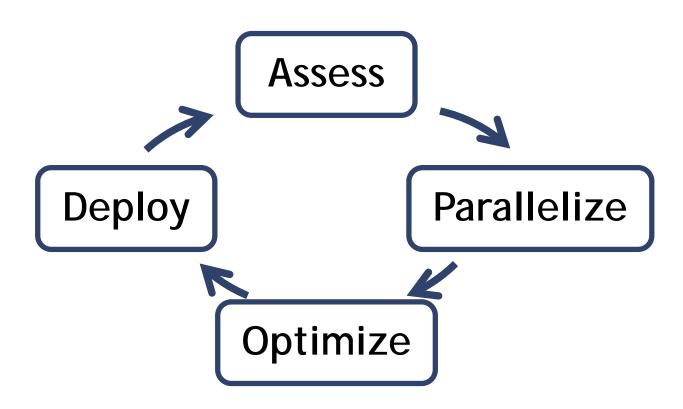
### **Analysis**



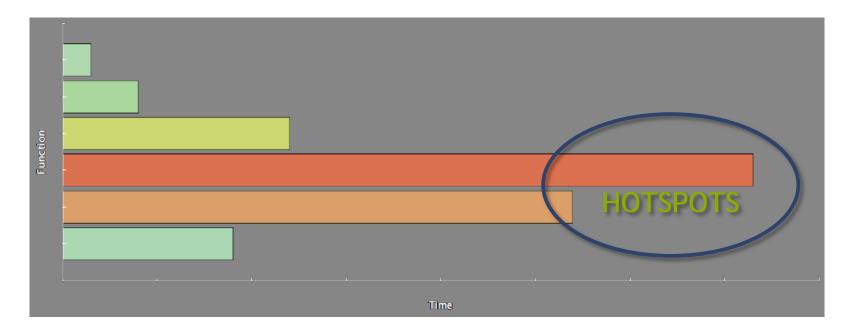
# **Profiler Summary**

- Many profile tools are available
- NVIDIA Provided
  - NVPROF: Command Line
  - NVVP: Visual profiler
  - NSIGHT: IDE (Visual Studio and Eclipse)
- 3<sup>rd</sup> Party
  - TAU
  - VAMPIR

# **Optimization**



## Assess



- Profile the code, find the hotspot(s)
- Focus your attention where it will give the most benefit



## **Parallelize**

## **Applications**

Libraries

Compiler Directives

Programming Languages

# **Optimize**

### **Timeline**



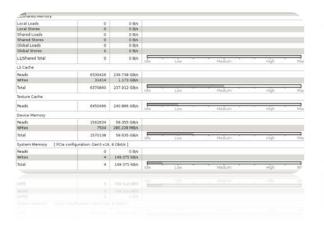
### Guided System

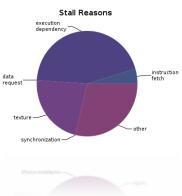


Rerun Analysis

If you modify the kernel you need to rerun your application to update this analysis.

### **Analysis**





## **Developer Tools - Debuggers**





https://developer.nvidia.com/debugging-solutions

## **CUDA-GDB**

- cuda-gdb is an extension of GDB
  - Provides seamless debugging of CUDA and CPU code
- Works on Linux and Macintosh
  - For a Windows debugger use NSIGHT Visual Studio Edition

http://docs.nvidia.com/cuda/cuda-gdb

## **CUDA-MEMCHECK**

- Memory debugging tool
  - No recompilation necessary%> cuda-memcheck ./exe
- Can detect the following errors
  - Memory leaks
  - Memory errors (OOB, misaligned access, illegal instruction, etc)
  - Race conditions
  - Illegal Barriers
  - Uninitialized Memory
- For line numbers use the following compiler flags:
  - Xcompiler -rdynamic -lineinfo

http://docs.nvidia.com/cuda/cuda-memcheck



### INTRODUÇÃO À PROGRAMAÇÃO PARA GPUS USANDO CUDA

Pedro Bruel phrb@ime.usp.br 29 de Setembro de 2015



Instituto de Matemática e Estatística Universidade de São Paulo